# TITANIC - Problema de Clasificación

Este problema nos proporciona distinta información de los pasajeros del famoso Titanic, trágico suceso donde el transátlanticos se hundió tras el choque con un iceberg. Causó la muerte de 1502 personas de las 2224 compuestas por pasajeros y tripulación. La información disponible de cada persona es:

- ID pasajero: Identificador del pasajero
- Pclass: Tipo de billete (1: primera, 2: segunda, 3: tercera clase)
- Name: Nombre completo del pasajero
- Sex: Género del pasajero
- Age: Edad
- SibSp: Número de hermanos o pareja a bordo
- Parch: Número de padres o hijos a bordo
- Ticket: Número de ticket
- Fare: Tarifa
- Cabin: Número de cabina
- Embarked: Puerta de embarque (C: Cherbourg, Q: Queenstown, S: Southampton)
- Survived: Si ha sobrevivido o no (1: Si, 0: No)

```
In [1]: |
        import numpy as np
        import pandas as pd
        import matplotlib.pyplot as plt
        import seaborn as sns
        from sklearn.preprocessing import OneHotEncoder, LabelEncoder, StandardSc
        from sklearn.model selection import StratifiedKFold, train test split, Gr
        from sklearn.metrics import confusion matrix
        from sklearn.linear model import LogisticRegression
        from sklearn.svm import SVC
        from sklearn.ensemble import RandomForestClassifier
        from sklearn.tree import DecisionTreeClassifier
        #Carga de datos
        train = pd.read_csv("./Titanic/train.csv")
        test = pd.read csv("./Titanic/test.csv")
        solucion = pd.read_csv("./Titanic/gender_submission.csv")
In [2]: print(train.columns.values)
```

```
['PassengerId' 'Survived' 'Pclass' 'Name' 'Sex' 'Age' 'SibSp' 'Parch' 'Ticket' 'Fare' 'Cabin' 'Embarked']

In [3]: train.head(5)
```

Out[3]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	F	
	0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2!	
	1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th	female	38.0	1	0	PC 17599	71.28	
	2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9:	
	3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.10	
	4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0!	

```
In [4]: #Conversion de columnas categoricas a binarias

train["male"]= [1 if i=="male" else 0 for i in train["Sex"]]
    train.head(5)
    test["male"]= [1 if i=="male" else 0 for i in test["Sex"]]
    test.head(5)
```

Out[4]:		PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin
	0	892	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN
	1	893	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN
	2	894	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN
	3	895	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN
	4	896	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875	NaN

# Limpieza de datos

```
In [5]: print("En el conjunto de entrenamiento se tienen:\n")
   for col in train.columns.tolist():
        print(col, "tiene", train[col].isnull().sum(), "valores nulos\n")

print("\n")
   print("En el conjunto de test se tienen ", len(test)," personas de los cu
   for col in test.columns.tolist():
        print(col, "tiene", test[col].isnull().sum(), "valores nulos\n")
```

En el conjunto de entrenamiento se tienen:

PassengerId tiene 0 valores nulos

Survived tiene 0 valores nulos

Pclass tiene 0 valores nulos

Name tiene 0 valores nulos

Sex tiene 0 valores nulos

Age tiene 177 valores nulos

SibSp tiene 0 valores nulos

Parch tiene 0 valores nulos

Ticket tiene 0 valores nulos

Fare tiene 0 valores nulos

Cabin tiene 687 valores nulos

Embarked tiene 2 valores nulos

male tiene 0 valores nulos

En el conjunto de test se tienen 418 personas de los cuales son:

PassengerId tiene 0 valores nulos

Pclass tiene 0 valores nulos

Name tiene 0 valores nulos

Sex tiene 0 valores nulos

Age tiene 86 valores nulos

SibSp tiene 0 valores nulos

Parch tiene 0 valores nulos

Ticket tiene 0 valores nulos

Fare tiene 1 valores nulos

Cabin tiene 327 valores nulos

Embarked tiene 0 valores nulos

male tiene 0 valores nulos

Las columnas de la edad, el número de cabina, la tarifa y donde embarcaron tienen valores nulos.

En el caso de la edad los valores nulos representan un 19.8% del total en training (similar en test), siendo necesario darles algún valor al no ser una cantidad pequeña de casos para poder eliminarlos, ni acercarse al total de casos para no tenerla en cuenta.

El número de cabina tiene un 77.1% de valores nulos en training (similar en test), es una cantidad alta de datos nulos donde podriamos intentar resolver el problema sin tenerlo en cuenta, pero que es una variable importante debido a que especifica la localización de la cabina en el barco y puede ser un factor importante en la supervivencia de los pasajeros.

La tarifa en el conjunto de test tiene un valor nulo, analizaremos la información de esa persona para asignar un valor con sentido.

Y finalmente dos personas con embarcación desconocida en el conjunto de training, que se intentará seguir el mismo procedimiento que con la tarifa.

In [6]:	train.corr()									
Out[6]:		PassengerId	Survived	Pclass	Age	SibSp	Parch			
	PassengerId	1.000000	-0.005007	-0.035144	0.036847	-0.057527	-0.001652	0.01		
	Survived	-0.005007	1.000000	-0.338481	-0.077221	-0.035322	0.081629	0.25		
	Pclass	-0.035144	-0.338481	1.000000	-0.369226	0.083081	0.018443	-0.54		
	Age	0.036847	-0.077221	-0.369226	1.000000	-0.308247	-0.189119	0.09		
	SibSp	-0.057527	-0.035322	0.083081	-0.308247	1.000000	0.414838	0.15		
	Parch	-0.001652	0.081629	0.018443	-0.189119	0.414838	1.000000	0.21		
	Fare	0.012658	0.257307	-0.549500	0.096067	0.159651	0.216225	1.00		

In [7]: test.corr()

0.131900

0.093254

-0.114631 -0.245489

0.042939 -0.543351

male

]:		PassengerId	Pclass	Age	SibSp	Parch	Fare	n
	PassengerId	1.000000	-0.026751	-0.034102	0.003818	0.043080	0.008211	0.023
	Pclass	-0.026751	1.000000	-0.492143	0.001087	0.018721	-0.577147	0.108
	Age	-0.034102	-0.492143	1.000000	-0.091587	-0.061249	0.337932	0.000
	SibSp	0.003818	0.001087	-0.091587	1.000000	0.306895	0.171539	-0.099
	Parch	0.043080	0.018721	-0.061249	0.306895	1.000000	0.230046	-0.159
	Fare	0.008211	-0.577147	0.337932	0.171539	0.230046	1.000000	-0.191
	male	0.023245	0.108615	0.000013	-0.099943	-0.159120	-0.191514	1.000

```
In [8]: todos = pd.concat([train,test],sort=True).reset_index(drop=True)
```

#### Edad

Out[7

```
In [9]:
         todos["Titulo"] = todos["Name"].str.split(",",expand=True)[1].str.split(".
         todos["Titulo"] = todos["Titulo"].replace(['Dona','Lady','the Countess','
         todos["Titulo"] = todos["Titulo"].replace(['Mme','Mlle'],'Miss',regex=Tru
         todos["Titulo"].value_counts()
         #Dr tiene 1 null(male 1 clase), 8 master con null, 28 Mrs con null, 50 Mi
                       757
          Mr
Out[9]:
          Miss
                       263
          Mrs
                       202
          Master
                        61
                         8
          Rev
          Dr
          Col
          Major
                         2
          Don
          Sir
          Capt
                         1
          Jonkheer
         Name: Titulo, dtype: int64
In [10]: edad_por_clase_genero = todos.groupby(["Sex","Pclass","Titulo"]).median()
         edad por clase genero
```

```
Sex
                   Pclass
                            Titulo
Out[10]:
          female
                   1
                             Dr
                                           49.0
                             Miss
                                           30.0
                                           45.0
                             Mrs
                   2
                             Miss
                                           20.0
                                           30.0
                             Mrs
                   3
                             Miss
                                           18.0
                                           31.0
                             Mrs
          male
                                           70.0
                   1
                             Capt
                                           54.5
                             Col
                             Don
                                           40.0
                                           47.0
                             Dr
                             Jonkheer
                                           38.0
                             Major
                                           48.5
                                            6.0
                             Master
                                           41.5
                             Mr
                             Sir
                                           49.0
                   2
                             Dr
                                           38.5
                             Master
                                            2.0
                                           30.0
                             Mr
                             Rev
                                           41.5
                   3
                                            6.0
                             Master
                                           26.0
          Name: Age, dtype: float64
```

```
In [11]: todos["Age"]=todos.groupby(["Sex","Pclass","Titulo"])["Age"].apply(lambda
```

La columna edad tiene correlacion con la clase en la que viaja la persona (un 0.37 en training y un 0.49 en test), combinando con el género para diferenciar más los distintos casos existentes. Además el nombre contiene un titulo que nos puede ayudar más aún para especificar la edad de aquellas personas en la que no este registrada.

#### Tarifa

```
In [12]: tarifa_po = todos.groupby(["SibSp","Pclass","Parch"]).median()["Fare"]
    tarifa_po
```

0 . [40]	SibSp	Pclas	ss Paro	nh.
Out[12]:	0	1	0	31.33960
	O	1	1	63.35830
			2	83.15830
		2		
		2	0	13.00000
			1	23.00000
			2	26.25000
			3	39.00000
		3	0	7.85420
			1	12.47500
			2	15.24580
			3	19.25830
			4	23.27085
			5	34.40625
	1	1	0	75.25000
			1	83.15830
			2	120.00000
			3	262.37500
			4	263.00000
		2	0	26.00000
			1	26.25000
			2	41.57920
			3	23.00000
		3	0	14.45625
			1	15.24580
			2	22.01250
			3	34.37500
			4	27.90000
			5	31.33125
			6	46.90000
			9	69.55000
	2	1	0	51.47920
	2	1	2	262.37500
		2	0	73.50000
		۷	1	33.00000
		2	3	18.75000
		3	0	19.83960
			1	19.25830
	•		2	34.37500
	3	1	2	263.00000
		2	0	21.00000
		3	0	16.92500
			1	22.02500
			2	27.90000
	4	3	1	34.40625
			2	31.27500
	5	3	2	46.90000
	8	3	2	69.55000
	Name:	Fare,	dtype:	float64

```
In [13]: # Pertenece a un hombre de clase 3 con 0 hijos y 0 hermanos/pareja
         todos["Fare"] = todos["Fare"].fillna(7.8542)
```

## • Embarque

```
embarked_po = todos.groupby(["Pclass","Embarked","male"]).median()["Fare"
          embarked_po
         Pclass Embarked
                            male
Out[14]:
                  С
                                     83.15830
                            1
                                     62.66875
                            0
                  Q
                                     90.00000
                            1
                                     90.00000
                  S
                            0
                                     78.85000
                            1
                                     35.50000
          2
                  С
                            0
                                     27.72080
                            1
                                     15.04580
                            0
                  Q
                                     12.35000
                            1
                                     12.35000
                  S
                            0
                                     23.00000
                            1
                                     13.00000
          3
                  С
                            0
                                     14.45420
                            1
                                      7.22920
                            0
                                      7.75000
                  Q
                            1
                                      7.75000
                  S
                            0
                                     13.77500
                            1
                                      8.05000
         Name: Fare, dtype: float64
In [15]: todos[todos["Embarked"].isnull()]
          # Dos mujeres supervivientes de 1ª clase con una tarifa de 80, Southampto
          todos["Embarked"] = todos["Embarked"].fillna('S')
          todos["Emb_C"]= [1 if i=="C" else 0 for i in todos["Embarked"]]
          todos["Emb_S"]= [1 if i=="S" else 0 for i in todos["Embarked"]]
          todos["Emb_Q"]= [1 if i=="Q" else 0 for i in todos["Embarked"]]
```

todos.head(5)

Out[15]:		Age	Cabin	Embarked	Fare	Name	Parch	PassengerId	Pclass	Sex	SibS
	0	22.0	NaN	S	7.2500	Braund, Mr. Owen Harris	0	1	3	male	
	1	38.0	C85	С	71.2833	Cumings, Mrs. John Bradley (Florence Briggs Th	0	2	1	female	
	2	26.0	NaN	S	7.9250	Heikkinen, Miss. Laina	0	3	3	female	(
	3	35.0	C123	S	53.1000	Futrelle, Mrs. Jacques Heath (Lily May Peel)	0	4	1	female	
	4	35.0	NaN	S	8.0500	Allen, Mr. William Henry	0	5	3	male	(

#### • Número de Cabina

Optamos por no tenerlo en cuenta ante la gran cantidad de datos null

# Tratamiento de datos

El porcentaje de hombres supervivientes es 18.890814558058924 , 109 sup ervivientes de 577 hombres.

```
In [19]: surv_mujer = surv.loc[surv["Sex"]=="female"]
    train_mujer = train.loc[train["Sex"]=="female"]

porc_mujeres = len(surv_mujer)/len(train_mujer)
    print("El porcentaje de mujeres supervivientes es ", porc_mujeres*100 ,",
```

El porcentaje de mujeres supervivientes es 74.20382165605095 , 233 supervivientes de 314 mujeres.

#### Clase

El porcentaje de personas supervivientes de primera clase es 62.96296296 296296, 136 supervivientes de 216 pasajeros de primera clase. El porcentaje de personas supervivientes de segunda clase es 47.28260869 565217, 87 supervivientes de 184 pasajeros de segunda clase. El porcentaje de personas supervivientes de tercera clase es 24.23625254 5824847, 119 supervivientes de 491 pasajeros de tercera clase.

## • Edad y Tarifa

```
In [21]: col continuas = ["Age", "Fare"]
          surv = train.loc[train["Survived"]==1]
          muerto = train.loc[train["Survived"]==0]
          fig, axs = plt.subplots(ncols= 2, nrows = 2, figsize=(20,20))
          for i, col in enumerate(col_continuas):
               sns.histplot(train["Survived"]==0][col], label = "Muerto",color
               sns.histplot(train[train["Survived"]==1][col], label = "Vivo", ax = a
               sns.histplot(train[col], label = "Entrenamiento",color='yellow', ax =
               sns.histplot(test[col], label = "Test", ax = axs[1][i])
               axs[0][i].legend()
               axs[1][i].legend()
               axs[0][i].set title("Distribucion de supervivientes en {}".format(col
          axs[1][0].set_title("Distribución de la edad")
          axs[1][1].set_title("Distribución de la tarifa")
          plt.show()
                       Distribucion de supervivientes en Age
                                                                   Distribucion de supervivientes en Fare
           120
                                                       200
                          Distribución de la edad
                                                                      Distribución de la tarifa
                                                                                     Entrenamiento
                                                       300
           150
                                                       200
                                                       100
```

Explicación de distribuciones en variables continuas, en género y clase

Para la edad podemos observar como los menores de edad tienen una proporción de más de la mitad de supervivientes, siendo asi también solamente en el intervalo de 30 a 35 años de edad. Los datos en los conjuntos de test y training vienen distribuidos de la misma manera, manteniendo así una proporción de los datos similar.

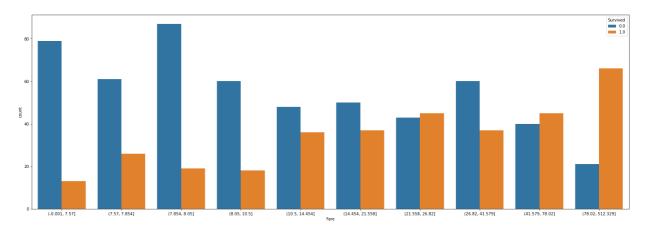
En cuanto a las tarifas, la gran mayoría de los pasajeros se encuentran por debajo de los 50, con más de 300 pasajeros en el conjunto de training con una tarifa menor a 10, por ello es ahi dónde se concentran el mayor número de supervivientes, pero con un ratio bajisimo de supervivencia debido a los más de 200 pasajeros que murieron con esa tarifa. El resto de intervalos obtiene un ratio de supervivientes mayor conforme va subiendo la tarifa del pasajero. El reparto de los datos en los conjuntos de training y test es similar en proporcion.

El género nos revela como el 74.2% de las mujeres logra sobrevivir (233 mujeres) pero tan solo un 18.9% de los hombres sobrevivieron (109 hombres), siendo un factor importante a la hora de evaluar la supervivencia del pasajero.

Y finalmente las clases de cada pasajero, dónde pertenecer a un grupo de pasajeros con una clase más privilegiada aumenta la probabilidad de supervivencia, o eso al menos parece indicar la estadistica con el porcentaje de personas que sobrevivieron por cada clase. Un 63% de supervivencia en los pasajeros de primera clase, un 47% si perteneces a la segunda clase, y tan solo un 24% en pasajeros de tercera clase. Cabe destacar que la cantidad de pasajeros de las clases primera y segunda estan balanceadas, con 216 de primera clase y 184 de segunda, pero que existen 491 pasajeros de tercera clase, que a pesar de ser más del doble de los pasajeros de primera clase, existen más supervivientes en el conjunto de entrenamiento de pasajeros de primera clase que de tercera.

• Ajuste caracteristicas para el modelo

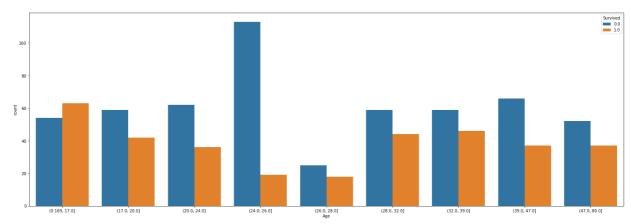
```
In [22]: todos['Fare'] = pd.qcut(todos['Fare'],10)
In [23]: fig, axs = plt.subplots(figsize=(27,9))
    sns.countplot(x="Fare",hue="Survived",data=todos)
Out[23]: <AxesSubplot:xlabel='Fare', ylabel='count'>
```



```
In [24]: todos['Age'] = pd.qcut(todos['Age'],9)
```

```
In [25]: fig, axs = plt.subplots(figsize=(27,9))
sns.countplot(x="Age", hue="Survived", data=todos)
```

Out[25]: <AxesSubplot:xlabel='Age', ylabel='count'>



```
In [26]: # Codificamos los intervalos en etiquetas
for col in col_continuas:
     todos[col] = LabelEncoder().fit_transform(todos[col])
```

Al dividir en intervalos podemos observar de mejor manera como se distribuyen los supervivientes (en naranja) a lo largo del conjunto con respecto a la edad y a la tarifa.

En la tarifa vemos que conforme más nos movemos a los intervalos de pasajeros que han pagado una tarifa mayor, por norma general, más ratio de supervivientes con respecto a fallecidos nos encontramos.

En cuanto a la edad, observamos como el intervalo con menores de edad es el único con más supervivientes que fallecidos, teniendo el resto de intervalos una proporción similar de un número algo mayor de fallecidos que supervivientes, salvo en el intervalo de 24 a 26 años, donde hay un número de supervivientes más bajo con respecto al resto de intervalos, pero que supera las 100 personas fallecidas, donde el siguiente de los intervalos con más fallecidos tiene ligeramente más de 60 personas.

# Entrenamiento modelo

In [27]:	todos.head(2)													
Out[27]:		Age	Cabin	Embarked	Fare	N	ame Pa	arch	Passenge	erld P	class	Sex	SibSp	Sı
	0 2		NaN	S	0	0	und, Mr. wen arris	0		1	3	male	1	
	1	6	C85	С	8	Cumings, Mrs. John Bradley (Florence Briggs Th		0	2		1 female		1	
In [28]:	to	dos :	= todos	s[["Passer	ngerI	d","S	urvive	ed","A	.ge","ma	ale","	Pclass"	,"Fa:	re",":	Par
In [29]:			head(2)			•				•			•	
Out[29]:		Pass	engerld	Survived	Age	male	Pclass	Fare	Parch	SibSp	Emb_C	Emb	_S E	mb_
	0		1	0.0	2	1	3	0	0	1	0		1	
	1		2	1.0	6	0	1	8	0	1	1		0	
In [30]:	<pre>train = todos.loc[:890] test = todos.loc[891:] test.reset_index(drop=True)</pre>													

Out[30]:		PassengerId	Survived	Age	male	Pclass	Fare	Parch	SibSp	Emb_C	Emb_S	Em
	0	892	NaN	6	1	3	1	0	0	0	0	
	1	893	NaN	7	0	3	0	0	1	0	1	
	2	894	NaN	8	1	2	3	0	0	0	0	
	3	895	NaN	4	1	3	3	0	0	0	1	
	4	896	NaN	2	0	3	4	1	1	0	1	
	•••					•••		•••	•••	•••	•••	
	413	1305	NaN	3	1	3	2	0	0	0	1	
	414	1306	NaN	6	0	1	9	0	0	1	0	
	415	1307	NaN	6	1	3	0	0	0	0	1	
	416	1308	NaN	3	1	3	2	0	0	0	1	
	417	1309	NaN	0	1	3	6	1	1	1	0	

418 rows × 11 columns

```
In [31]: X_train = StandardScaler().fit_transform(train[["Age","male","Pclass","Fa
y_train = train["Survived"].values
X_test = StandardScaler().fit_transform(test[["Age","male","Pclass","Fare
print(X_train.shape)
print(y_train.shape)
print(X_test.shape)
(891, 9)
(891,)
(418, 9)
```

## • Regresion Logística

```
In [33]: prediccion = pd.DataFrame()
    prediccion["PassengerId"] = test["PassengerId"]
    prediccion["Survived"] = gs.predict(X_test)

accuracy = gs.score(X_test,solucion["Survived"])
    print(confusion_matrix(solucion["Survived"],prediccion["Survived"]))
    print(accuracy)

[[255    11]
    [ 17    135]]
    0.9330143540669856
```

### • Suport Vector Machine

```
In [34]: param grid = {'kernel': ["linear"], 'C': [0.1, 1,10,100]}
  svc = GridSearchCV(SVC(), param grid=param grid,refit=True,verbose=2,cv=1
  svc.fit(X train,y train)
  print("best_params: " + str(svc.best_estimator_))
  print("best params: " + str(svc.best params ))
  print("best_score: " + str(svc.best_score_))
  Fitting 10 folds for each of 4 candidates, totalling 40 fits
  0.0s
  [CV] END ......C=1, kernel=linear; total time=
```

```
0.0s
[CV] END ......C=100, kernel=linear; total time=
2.1s
0.4s
[CV] END ......C=100, kernel=linear; total time=
0.1s
[CV] END ......C=100, kernel=linear; total time=
0.4s
[CV] END ......C=100, kernel=linear; total time=
0.8s
0.8s
[CV] END ......C=100, kernel=linear; total time=
0.6s
[CV] END ......C=100, kernel=linear; total time=
0.8s
best_params: SVC(C=0.1, kernel='linear')
best params: {'C': 0.1, 'kernel': 'linear'}
best score: 0.786729088639201
```

```
In [35]: prediccion = pd.DataFrame()
    prediccion["PassengerId"] = test["PassengerId"]
    prediccion["Survived"] = svc.predict(X_test)
    print(prediccion)

accuracy = svc.score(X_test,solucion["Survived"])
    print(confusion_matrix(solucion["Survived"],prediccion["Survived"]))
    print(accuracy)
```

```
PassengerId Survived
891
               892
                           0.0
892
               893
                           1.0
893
               894
                           0.0
               895
                           0.0
894
895
               896
                           1.0
               . . .
                           . . .
1304
              1305
                           0.0
                           1.0
1305
              1306
1306
              1307
                           0.0
1307
              1308
                           0.0
1308
              1309
                           0.0
[418 rows x 2 columns]
[[266
        0 ]
[ 0 152]]
1.0
```

#### Random Forrest

[CV] END .....criterion=gini, max depth=3, n estimators=100; total time=

[CV] END .....criterion=gini, max\_depth=3, n\_estimators=100; total time=

[CV] END .....criterion=gini, max\_depth=3, n\_estimators=100; total time=

[CV] END .....criterion=gini, max depth=3, n estimators=200; total time=

[CV] END .....criterion=gini, max\_depth=3, n\_estimators=200; total time=

[CV] END .....criterion=gini, max\_depth=3, n\_estimators=200; total time=

0.0s

0.0s

0.0s

0.1s

0.1s

```
0.1s
[CV] END .....criterion=gini, max depth=3, n estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max_depth=3, n_estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max_depth=3, n_estimators=400; total time=
0.3s
[CV] END .....criterion=gini, max depth=3, n estimators=400; total time=
0.3s
[CV] END .....criterion=gini, max depth=3, n estimators=400; total time=
0.3s
[CV] END .....criterion=gini, max depth=3, n estimators=400; total time=
0.3s
[CV] END .....criterion=gini, max depth=3, n estimators=400; total time=
0.3s
[CV] END .....criterion=gini, max_depth=5, n_estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max_depth=5, n_estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=5, n estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=5, n estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max_depth=5, n_estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=5, n estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max depth=5, n estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max depth=5, n estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max depth=5, n estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max depth=5, n estimators=200; total time=
[CV] END .....criterion=gini, max depth=5, n estimators=400; total time=
0.4s
[CV] END .....criterion=gini, max_depth=5, n_estimators=400; total time=
0.4s
[CV] END .....criterion=gini, max_depth=5, n_estimators=400; total time=
0.3s
[CV] END .....criterion=gini, max depth=5, n estimators=400; total time=
0.4s
[CV] END .....criterion=gini, max depth=5, n estimators=400; total time=
0.4s
[CV] END .....criterion=gini, max_depth=6, n_estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=6, n estimators=100; total time=
[CV] END .....criterion=gini, max_depth=6, n_estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=6, n estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=6, n estimators=100; total time=
0.1s
[CV] END .....criterion=gini, max depth=6, n estimators=200; total time=
0.1s
```

```
[CV] END .....criterion=gini, max depth=6, n estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max depth=6, n estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max depth=6, n estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max_depth=6, n_estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max depth=6, n estimators=400; total time=
0.5s
[CV] END .....criterion=gini, max_depth=6, n_estimators=400; total time=
0.6s
[CV] END .....criterion=gini, max depth=6, n estimators=400; total time=
0.6s
[CV] END .....criterion=gini, max_depth=6, n_estimators=400; total time=
0.6s
[CV] END .....criterion=gini, max_depth=6, n_estimators=400; total time=
0.6s
[CV] END .....criterion=gini, max depth=7, n estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=7, n estimators=100; total time=
0.0s
[CV] END .....criterion=gini, max depth=7, n estimators=100; total time=
0.1s
[CV] END .....criterion=gini, max_depth=7, n_estimators=100; total time=
0.1s
[CV] END .....criterion=gini, max_depth=7, n_estimators=100; total time=
0.1s
[CV] END .....criterion=gini, max_depth=7, n_estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max depth=7, n estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max depth=7, n estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max depth=7, n estimators=200; total time=
0.1s
[CV] END .....criterion=gini, max depth=7, n estimators=200; total time=
0.2s
[CV] END .....criterion=gini, max_depth=7, n_estimators=400; total time=
0.4s
[CV] END .....criterion=gini, max depth=7, n estimators=400; total time=
[CV] END .....criterion=gini, max depth=7, n estimators=400; total time=
0.4s
[CV] END .....criterion=gini, max depth=7, n estimators=400; total time=
0.5s
[CV] END .....criterion=gini, max_depth=7, n_estimators=400; total time=
0.4s
[CV] END ...criterion=entropy, max depth=3, n estimators=100; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=3, n_estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=3, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=3, n estimators=100; total time=
[CV] END ...criterion=entropy, max_depth=3, n_estimators=100; total time=
```

```
0.0s
[CV] END ...criterion=entropy, max depth=3, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=3, n_estimators=200; total time=
0.2s
[CV] END ...criterion=entropy, max_depth=3, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=3, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=3, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=3, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=3, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max_depth=3, n_estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max_depth=3, n_estimators=400; total time=
[CV] END ...criterion=entropy, max depth=3, n estimators=400; total time=
[CV] END ...criterion=entropy, max depth=5, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=5, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=5, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=5, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=200; total time=
[CV] END ...criterion=entropy, max depth=5, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=5, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=5, n estimators=400; total time=
0.4s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=400; total time=
0.4s
[CV] END ...criterion=entropy, max_depth=5, n_estimators=400; total time=
[CV] END ...criterion=entropy, max_depth=5, n_estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=6, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=6, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=6, n estimators=100; total time=
0.0s
```

```
[CV] END ...criterion=entropy, max_depth=6, n_estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=6, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max_depth=6, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=6, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=6, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=6, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=6, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=6, n_estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max_depth=6, n_estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=6, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=6, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=6, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=100; total time=
[CV] END ...criterion=entropy, max_depth=7, n_estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=7, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=7, n estimators=100; total time=
0.0s
[CV] END ...criterion=entropy, max depth=7, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=7, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=200; total time=
[CV] END ...criterion=entropy, max depth=7, n estimators=200; total time=
0.1s
[CV] END ...criterion=entropy, max depth=7, n estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=400; total time=
0.3s
[CV] END ...criterion=entropy, max depth=7, n estimators=400; total time=
0.4s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=400; total time=
0.4s
[CV] END ...criterion=entropy, max_depth=7, n_estimators=400; total time=
0.3s
best params: RandomForestClassifier(criterion='entropy', max depth=6, n e
stimators=400)
best_params: {'criterion': 'entropy', 'max_depth': 6, 'n_estimators': 400
```

```
best_score: 0.8260247316552632

In [37]: prediccion = pd.DataFrame()
    prediccion["PassengerId"] = test["PassengerId"]
    prediccion["Survived"] = r_for.predict(X_test)
    print(prediccion)

accuracy = r_for.score(X_test,solucion["Survived"])
    print(confusion_matrix(solucion["Survived"],prediccion["Survived"]))
    print(accuracy)
```

```
PassengerId Survived
891
               892
                          0.0
               893
892
                          0.0
893
               894
                          0.0
894
               895
                          0.0
895
               896
                          1.0
               . . .
                          . . .
1304
              1305
                          0.0
1305
              1306
                          1.0
1306
              1307
                          0.0
1307
              1308
                          0.0
1308
              1309
                          1.0
[418 rows x 2 columns]
[[251 15]
[ 34 118]]
0.8827751196172249
```

## Decision Tree

```
In [38]: param grid = {'ccp alpha': [0.001,0.01,0.1], 'max depth': [5,6,7,8],'crit
         d tree = GridSearchCV(DecisionTreeClassifier(), param grid=param grid,ver
         d_tree.fit(X_train,y_train)
         print("best_params: " + str(d_tree.best_estimator_))
         print("best_params: " + str(d_tree.best_params_))
         print("best score: " + str(d tree.best score ))
         Fitting 5 folds for each of 24 candidates, totalling 120 fits
         [CV] END .....ccp alpha=0.001, criterion=gini, max depth=5; total time=
         0.0s
         [CV] END .....ccp alpha=0.001, criterion=gini, max depth=5; total time=
         0.0s
         [CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=5; total time=
         0.0s
         [CV] END .....ccp alpha=0.001, criterion=gini, max depth=5; total time=
         0.0s
         [CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=5; total time=
         0.0s
         [CV] END .....ccp alpha=0.001, criterion=gini, max depth=6; total time=
         0.0s
         [CV] END .....ccp alpha=0.001, criterion=gini, max depth=6; total time=
```

```
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.001, criterion=gini, max_depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.001, criterion=gini, max depth=8; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=5; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=5; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=5; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=5; total time=
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=5; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=6; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=6; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=6; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=6; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max depth=6; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=7; total time=
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=7; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=7; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=7; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=7; total time=
0.0s
```

```
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=8; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=8; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=8; total time=
0.0s
[CV] END ....ccp_alpha=0.001, criterion=entropy, max_depth=8; total time=
0.0s
[CV] END ....ccp alpha=0.001, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=5; total time=
0.0s
[CV] END ......ccp alpha=0.01, criterion=gini, max depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=5; total time=
0.0s
[CV] END ......ccp alpha=0.01, criterion=gini, max depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=8; total time=
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=gini, max_depth=8; total time=
0.0s
[CV] END ......ccp alpha=0.01, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=entropy, max_depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=entropy, max depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=5; total time=
0.0s
[CV] END ....ccp_alpha=0.01, criterion=entropy, max_depth=5; total time=
```

```
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=entropy, max_depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=entropy, max_depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=entropy, max_depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.01, criterion=entropy, max_depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=7; total time=
0.0s
[CV] END ....ccp_alpha=0.01, criterion=entropy, max_depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.01, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=7; total time=
0.0s
```

```
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=gini, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=gini, max_depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=5; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=5; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=6; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=6; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=7; total time=
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=7; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=7; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max_depth=8; total time=
0.0s
[CV] END .....ccp_alpha=0.1, criterion=entropy, max depth=8; total time=
0.0s
[CV] END .....ccp alpha=0.1, criterion=entropy, max depth=8; total time=
0.0s
best_params: DecisionTreeClassifier(ccp_alpha=0.01, criterion='entropy',
```

```
max depth=5)
         best_params: {'ccp_alpha': 0.01, 'criterion': 'entropy', 'max_depth': 5}
         best score: 0.8080660347749669
In [39]: prediccion = pd.DataFrame()
         prediccion["PassengerId"] = test["PassengerId"]
         prediccion["Survived"] = d_tree.predict(X_test)
         print(prediccion)
         accuracy = d_tree.score(X_test,solucion["Survived"])
         print(confusion matrix(solucion["Survived"],prediccion["Survived"]))
         print(accuracy)
               PassengerId Survived
```

	Passengeria Surv	rived
891	892	0.0
892	893	1.0
893	894	0.0
894	895	0.0
895	896	1.0
• • •	• • •	• • •
1304	1305	0.0
1305	1306	1.0
1306	1307	0.0
1307	1308	0.0
1308	1309	1.0
[[253	rows x 2 columns]	

```
[ 4 148]]
0.9593301435406698
```

# **Conclusiones**

Se han probado 4 modelos distintos para la predicción del conjunto test: Regresión Logística, Vectores de soporte, Árboles aleatorios y Árboles de decisión.

Con todos los modelos se ha realizado una validación cruzada con la funcion GridSearchCV, que nos sirve además para ajustar mejor los hiperparámetros del modelo a nuestro problema, los resultados con respecto a los conjuntos de validación de los 4 modelos rondan entre un 78% y 82% de accuracy, pero curiosamente los mejores resultados en la precisión del conjunto de test se observan en los modelos con menor precisión (Support Vector Machine y Decision Tree), alcanzando un 100% de precisión en test para SVC y un 95.9% de precision para DecisionTreeClassifier.

```
In []:
```